

Sistem Prediksi Multi-Horizon Harga Bitcoin Berbasis Offchain, Onchain, dan Macro Economy data menggunakan LSTM-Attention untuk Mendukung Kebijakan Investasi Nasional

Muhammad Firdaus¹, Elzandi Irfan Zikra², Dyah Ayu Retnoningsih³

¹Fakultas Teknologi Maju dan Multidisiplin Universitas Airlangga, Surabaya, 60111, email: muhammad.firdaus-2024@ftmm.unair.ac.id

²Fakultas Teknologi Maju dan Multidisiplin Universitas Airlangga, Surabaya, 60111, email: elzandi.fan.zikra-2022@ftmm.unair.ac.id

³Fakultas Teknologi Maju dan Multidisiplin Universitas Airlangga, Surabaya, 60111, email: dyah.ayu.retnoningsih-2022@ftmm.unair.ac.id
Corresponding Author: Muhammad Firdaus

INTISARI — Bitcoin (BTC) merupakan aset digital dengan volatilitas harga tinggi yang dipengaruhi oleh sentimen pasar, kebijakan moneter, dan faktor teknis *blockchain*. Di Indonesia, risiko investasi tradisional meningkat akibat ketidakstabilan ekonomi global, kebijakan pajak kripto, dan keterbatasan instrumen lindung nilai. Penelitian terdahulu umumnya menggunakan data historis dengan *horizon* tunggal tanpa integrasi indikator teknikal, metrik *on-chain/off-chain*, dan variabel makroekonomi, sehingga kurang adaptif terhadap dinamika pasar. Penelitian ini mengembangkan model *Multi-Horizon Forecasting* berbasis *Bidirectional Long Short-Term Memory*, dan mekanisme *Attention (LSTM-Attention)* untuk memprediksi harga Bitcoin pada sepuluh *horizon* waktu (1 jam–30 hari). Dataset mencakup harga historis, indikator teknikal, metrik *on-chain/off-chain*, dan variabel makroekonomi. Evaluasi menggunakan *Mean Absolute Percentage Error (MAPE)*, *Root Mean Squared Error (RMSE)*, dan *Mean Absolute Error (MAE)*. Hasil menunjukkan MAPE <0,65% pada *horizon* 1–3 jam, <2% pada *horizon* 6–24 jam, dan hingga 15% pada *horizon* 3–30 hari. Analisis fitur mengidentifikasi variabel kunci seperti biaya transaksi rata-rata, arus modal global, dan suku bunga AS. Model ini berpotensi menjadi *Digital Asset Early Warning System* bagi Lembaga Keuangan Negara untuk mendukung kebijakan adaptif dalam pengelolaan risiko aset digital.

KATA KUNCI — Bitcoin, Prediksi *Multi-Horizon*, *LSTM-Attention*, Data Multi-Sumber, *CNN*, *Bi-LSTM*, Metrik *On-Chain/Off-Chain*, Variabel Makroekonomi, *Digital Asset Early Warning System*, *Data Mining*.

I. PENDAHULUAN

Bitcoin (BTC) adalah aset digital berbasis teknologi *blockchain* yang memungkinkan transaksi *peer-to-peer* tanpa keterlibatan otoritas pusat seperti bank [1]. Mekanisme terdesentralisasi ini menawarkan transparansi dan akses global, namun di sisi lain memicu volatilitas harga yang tinggi. Dalam satu dekade terakhir, pergerakan harga Bitcoin menjadi salah satu fenomena paling dinamis di pasar keuangan global nilainya dapat melonjak atau anjlok dalam hitungan jam, dipicu oleh interaksi kompleks antara sentimen pasar, kebijakan moneter, dan faktor teknis jaringan *blockchain*. Volatilitas harian Bitcoin kerap melampaui 10%, meskipun pada akhir 2023 tingkatnya tercatat lebih rendah dibandingkan 33 saham terpilih dalam indeks S&P 500 [2]. Karakteristik ini menjadikan Bitcoin bukan sekadar instrumen spekulatif, tetapi juga subjek penelitian strategis di bidang analisis data dan prediksi pasar.

Di Indonesia, lanskap investasi menghadapi tekanan ganda dari ketidakstabilan ekonomi global dan domestik. Instrumen konvensional seperti saham, obligasi, dan properti tidak luput dari risiko, terutama akibat ketergantungan pada dolar AS, fluktuasi nilai tukar, dan hambatan akses bagi investor ritel. Penurunan investasi asing langsung sebesar 6,95% pada kuartal II 2025 menjadi indikator lemahnya sentimen pasar di tengah ketidakpastian geopolitik. Selain itu, kebijakan pajak transaksi kripto yang akan berlaku pada Agustus 2025 diperkirakan menekan likuiditas pasar aset digital domestik [3]. Kondisi ini mendorong kebutuhan akan instrumen investasi yang tidak sepenuhnya berkorelasi dengan aset konvensional, mampu merespons perubahan pasar secara cepat, dan dapat berperan sebagai instrumen diversifikasi portofolio maupun *hedging* terhadap volatilitas ekonomi global [4]–[6].

Namun, meskipun memiliki potensi strategis, prediksi harga Bitcoin masih menghadapi keterbatasan metodologis. Sebagian besar studi terdahulu memanfaatkan data historis dengan *horizon* waktu tunggal atau terbatas, tanpa mengintegrasikan indikator teknikal, metrik *on-chain/off-chain*, dan variabel makroekonomi secara komprehensif [7][8]. Pendekatan tersebut membatasi kemampuan model dalam menangkap hubungan non-linear dan pola temporal yang kompleks, sehingga hasil prediksi kurang adaptif terhadap dinamika pasar yang berubah cepat. Celah penelitian (*research gap*) ini menuntut pendekatan yang mampu memproses data multi-sumber secara simultan dan memprediksi pada berbagai *horizon* waktu untuk meningkatkan akurasi dan relevansi hasil.

Penelitian ini mengusulkan model *Long Short-Term Memory (LSTM)* ber-*Attention* untuk memprediksi harga Bitcoin secara simultan pada sepuluh *horizon* waktu, mulai dari satu jam hingga 30 hari. Model ini mengintegrasikan harga historis, indikator teknikal, metrik *on-chain/off-chain*, dan variabel makroekonomi, sehingga mampu merepresentasikan dinamika pasar secara lebih menyeluruh. Evaluasi kinerja dilakukan menggunakan *Mean Absolute Percentage Error (MAPE)*, *Root Mean Squared Error (RMSE)*, dan *Mean Absolute Error (MAE)*. Hasil yang diharapkan adalah model prediksi yang unggul secara teknis, mampu berfungsi sebagai *early warning system* bagi lembaga keuangan negara, seperti Bank Indonesia dan Kementerian Keuangan, dalam merumuskan kebijakan investasi nasional yang adaptif terhadap faktor eksternal yang kompleks.

II. KAJIAN TEORI

A. Bitcoin

Bitcoin adalah mata uang kripto terdesentralisasi yang diperkenalkan oleh Satoshi [9] melalui *whitepaper* berjudul *Bitcoin: A Peer-to-Peer Electronic Cash System*. Sistem ini memanfaatkan teknologi *blockchain* sebagai buku besar publik yang menyimpan riwayat transaksi secara terdistribusi dan aman melalui mekanisme *cryptographic hashing* [10].

Berbeda dengan mata uang konvensional yang dikendalikan oleh otoritas moneter, Bitcoin bersifat *peer-to-peer*, sehingga validasi transaksi dilakukan oleh jaringan *node* menggunakan protokol *Proof-of-Work*. Karakteristik ini menjadikan Bitcoin memiliki volatilitas harga yang tinggi akibat interaksi kompleks antara faktor permintaan–penawaran, regulasi, sentimen pasar, dan dinamika jaringan [11].

B. Data On-Chain, Off-Chain, dan Indikator

Makroekonomi

Analisis harga Bitcoin dapat menggunakan tiga sumber data utama:

1) Data On-Chain

Mengacu pada metrik yang berasal dari aktivitas langsung di jaringan *blockchain*, seperti jumlah transaksi, *wallet address* aktif, *exchange inflow/outflow*, *hash rate*, dan total pasokan beredar [12]. Data ini mencerminkan kesehatan jaringan dan perilaku pelaku pasar secara fundamental.

2) Data On-Chain

Mencakup data perdagangan di bursa kripto seperti harga historis, volume transaksi, volatilitas, dan indikator teknikal (*Relative Strength Index*, *Moving Average*, dll.) yang berasal dari pasar sekunder [13].

3) Indikator Makroekonomi

Termasuk variabel eksternal seperti suku bunga bank sentral (*Federal Funds Rate*), indeks nilai tukar dolar AS (DXY), inflasi (*Consumer Price Index*), dan harga emas yang dapat memengaruhi arus modal ke aset berisiko seperti Bitcoin [14].

C. Investasi

Investasi didefinisikan sebagai upaya menempatkan modal pada instrumen finansial maupun non-finansial dengan tujuan utama meraih keuntungan di masa depan [15]. Instrumen finansial umumnya mencakup saham, obligasi, dan reksa dana, sedangkan instrumen non-finansial meliputi properti, emas, dan komoditas lainnya [16]. Di Indonesia, investasi memegang peran kunci dalam mendorong pertumbuhan ekonomi nasional, membuka lapangan kerja baru, serta meningkatkan pemerataan kekayaan dan kesejahteraan masyarakat [17].

1) Konteks dan Tantangan Investasi di Indonesia

Meskipun potensi ekonomi Indonesia besar, ekosistem investasi lokal masih menghadapi beberapa hambatan utama. Pertama, volatilitas pasar yang tinggi dipicu oleh ketidakpastian global dan sentimen domestik meningkatkan risiko bagi investor ritel [18]. Kedua, ketergantungan pada dolar AS menjadikan fluktuasi nilai tukar berdampak langsung pada imbal hasil investasi. Ketiga, akses terbatas bagi investor ritel karena instrumen berkualitas tinggi seperti derivatif dan obligasi korporasi memerlukan modal besar dan prosedur kompleks menghambat partisipasi masyarakat kecil dan menengah. Keempat, tantangan transparansi dan integritas kasus korupsi dan lemahnya mekanisme pengawasan di sektor

keuangan mengikis kepercayaan publik dan memperlambat aliran modal ke sektor riil [19].

2) Bitcoin sebagai Solusi Diversifikasi

Bitcoin muncul sebagai alternatif yang potensial untuk mengatasi tantangan investasi di Indonesia. Pertama, likuiditas tinggi karena pasar kripto beroperasi 24/7 memungkinkan investor melakukan transaksi kapan saja tanpa terikat jadwal pasar konvensional [16]. Kedua, transparansi berbasis *blockchain* di mana setiap transaksi tercatat permanen dalam buku besar publik mengurangi risiko manipulasi dan meningkatkan akuntabilitas [19]. Ketiga, independensi dari pasar tradisional karena korelasi harga Bitcoin yang rendah dengan indeks saham dan obligasi dapat meredam volatilitas portofolio yang dominan pada instrumen konvensional [16]. Dengan demikian, adopsi Bitcoin berpotensi memperluas inklusivitas investasi ritel dan mengurangi ketergantungan pada dolar AS serta instrumen keuangan tradisional [19].

D. Time Series

Analisis deret waktu adalah teknik statistik yang digunakan untuk memodelkan dan memprediksi nilai masa depan berdasarkan pola historis dalam data berurutan pada interval waktu tertentu. Dalam konteks investasi nasional, metode ini telah dimanfaatkan untuk meramalkan indikator makroekonomi yang berdampak langsung pada kebijakan publik dan keputusan bisnis. Contohnya, model ARIMA banyak digunakan dalam memprediksi Indeks Harga Konsumen (CPI) di Indonesia dengan akurasi yang memadai [20]. Sementara itu, pendekatan GARCH telah digunakan untuk memahami dampak risiko geopolitik terhadap volatilitas nilai tukar di Indonesia [21]. Di sektor komoditas, teknik seperti STL dan LSTM telah terbukti efektif untuk meramalkan harga komoditas penting seperti beras dan kelapa sawit [22].

Pada ranah aset digital, metode yang sama juga dipakai untuk meramalkan harga Bitcoin yang volatil tinggi. ARIMA menargetkan pola linier dalam data stasioner [23], sedangkan GARCH menangani perubahan volatilitas pasar [24]. Sementara itu, LSTM dirancang untuk mengatasi ketergantungan jangka panjang dalam data deret waktu [25] dan terbukti unggul dalam melakukan prediksi harga Bitcoin [26]. Dekomposisi STL juga membantu memisahkan tren jangka panjang dan pola musiman [27]. Selain itu, kombinasi indikator teknikal dan metrik *on-chain/off-chain* telah terbukti meningkatkan akurasi prediksi, memberikan wawasan holistik penting bagi kebijakan investasi nasional [28].

Dengan menggabungkan berbagai teknik deret waktu dan sumber data komprehensif, penelitian ini memperluas aplikasi analisis pasar tradisional ke pasar aset digital. Model prediksi harga Bitcoin *multi-horizon* yang diusulkan diharapkan menjadi alat ukur dinamika pasar digital sekaligus mendukung keputusan investasi nasional yang lebih responsif dan berbasis data.

E. Prediksi Harga Bitcoin dan Multi-Horizon Forecasting

Prediksi harga Bitcoin merupakan permasalahan *time series forecasting* yang kompleks karena data bersifat non-linier, non-stasioner, dan sangat dipengaruhi oleh faktor internal maupun eksternal [1][8]. Salah satu pendekatan yang efektif adalah *multi-horizon forecasting*, yang bertujuan memprediksi nilai pada beberapa titik waktu di masa depan secara langsung

(*direct multi-step forecasting*) tanpa melalui proses peramalan bertahap (*recursive*) [29].

Keunggulan metode ini terletak pada kemampuannya mengurangi akumulasi kesalahan prediksi dan memungkinkan analisis tren jangka pendek hingga jangka panjang secara simultan, yang sangat relevan untuk aset kripto dengan volatilitas tinggi seperti Bitcoin [27][29].

F. Model Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) adalah jenis khusus dari Recurrent Neural Network (RNN) yang dirancang untuk mengatasi masalah *vanishing gradient*, yang sering dihadapi oleh RNN pada data dengan dependensi jangka panjang. LSTM memiliki struktur unik yang terdiri dari *cell state*, *input gate*, *forget gate*, dan *output gate*, yang memungkinkan model untuk menyimpan, melupakan, dan mengeluarkan informasi secara selektif. Keunggulan utama LSTM terletak pada kemampuannya untuk mengingat informasi relevan dalam data deret waktu, membuatnya sangat efektif untuk memprediksi harga Bitcoin yang menunjukkan pola fluktuasi jangka panjang dan volatilitas tinggi. [25][30].

Persamaan matematis LSTM:

$$\begin{aligned} f_t &= \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \\ i_t &= \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \\ \bar{C}_t &= \tanh(W_c \cdot [h_{t-1}, x_t] + b_c) \\ C_t &= f_t * C_{t-1} + i_t * \bar{C}_t \\ o_t &= \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \\ h_t &= o_t * \tanh(C_t) \end{aligned}$$

Pada model LSTM, x_t adalah vektor input pada waktu ke- t yang berisi data masukan seperti harga, volume, atau indikator teknikal, sedangkan h_{t-1} merupakan *hidden state* sebelumnya yang membawa memori jangka pendek dari langkah sebelumnya. Parameter pembelajaran meliputi matriks bobot W_f, W_c, W_o, W_i untuk masing-masing *gate* serta bias b_f, b_i, b_c, b_o yang menyesuaikan aktivasi. *Forget gate* f_t mengatur seberapa banyak memori lama (C_{t-1}) dilupakan, sementara *input gate* (i_t) menentukan porsi informasi baru yang disimpan, yang nilainya berasal dari *candidate cell state* ($\bar{C}_t$) hasil fungsi tanh. *Cell state* lama (C_t) diperbarui menjadi (C_{t-1}) melalui kombinasi memori lama dan baru. Selanjutnya, *output gate* o_t mengontrol besaran memori yang diteruskan menjadi *hidden state* baru h_t , yang kemudian digunakan baik untuk prediksi maupun sebagai masukan ke timestep berikutnya.

LSTM dapat menangani ketergantungan temporal yang kompleks, dan telah terbukti unggul dalam memprediksi pergerakan harga aset keuangan, termasuk Bitcoin, dibandingkan dengan model tradisional seperti ARIMA. Dengan mengatasi masalah jangka panjang, LSTM mampu memberikan prediksi yang lebih akurat dalam analisis deret waktu yang bersifat dinamis, seperti pasar kripto [29][30].

G. Attention Mechanism

Mekanisme *attention* dalam model *deep learning* memungkinkan model untuk fokus pada bagian data masukan

yang lebih relevan untuk tugas prediksi. Dalam konteks prediksi harga Bitcoin, LSTM-Attention digunakan untuk memberikan perhatian lebih pada bagian data yang menunjukkan perubahan signifikan, seperti lonjakan harga atau pergerakan pasar yang penting. *Self-attention*, yang digunakan dalam model *Transformer*, meningkatkan efisiensi dengan menilai pentingnya setiap elemen dalam urutan data relatif terhadap elemen lainnya, memungkinkan model untuk memperhatikan hubungan jangka panjang yang lebih kompleks dalam data deret waktu [31]. Mekanisme ini dapat meningkatkan akurasi model prediksi harga Bitcoin dengan memfokuskan model pada faktor-faktor penting dalam data historis yang mempengaruhi pergerakan harga.

III. USULAN PENELITIAN

Penelitian ini mengintegrasikan tiga sumber data utama, yaitu data *off-chain*, *on-chain*, dan makroekonomi, ke dalam satu kerangka prediksi *multi-horizon* yang koheren. Pendekatan ini memungkinkan model untuk secara simultan menangkap dinamika fluktuasi harga dan volume historis, aktivitas jaringan *blockchain*, serta tekanan dan sinyal dari indikator makroekonomi. Rancangan model yang digunakan memadukan beberapa teknik komputasi canggih, termasuk ekstraksi fitur lokal melalui lapisan konvolusional, pemodelan sekuens dua arah dengan *Bidirectional Long Short-Term Memory* (BiLSTM), mekanisme perhatian kontekstual melalui *multi-head attention*, serta *embedding* khusus yang disesuaikan dengan setiap horizon prediksi. Kombinasi ini menghasilkan kapasitas representasi yang lebih kaya dan fleksibel dibandingkan dengan studi sebelumnya [29].

Dari segi cakupan dataset, beberapa studi awal menggunakan data *off-chain* seperti harga dan volume harian untuk *horizon* prediksi pendek (misalnya 1–7 hari) serta menggabungkan model *ensemble* seperti LSTM, GRU, CNN, dan TCN yang digabungkan oleh *meta-learner* seperti XGBoost [32]. Studi lain memperluas pendekatan ini dengan menambahkan dimensi sentimen dan data OHLCV, menggunakan model *Temporal Fusion Transformer* (TFT) yang dimodifikasi untuk memperbaiki ketelitian prediksi harga kripto [28].

Perbedaan signifikan lainnya terletak pada resolusi temporal yang digunakan. Sebagian besar penelitian sebelumnya menggunakan data harian yang cenderung mengaburkan fluktuasi harga jangka pendek. Dalam penelitian ini, digunakan data beresolusi jam dengan *window size* selama 48 jam, yang memungkinkan pendeteksian pola volatilitas jangka pendek (antara satu hingga dua belas jam) yang sering kali tidak tertangkap pada level agregasi harian. Rentang waktu prediksi yang diusulkan pun jauh lebih komprehensif, mencakup sepuluh *horizon* mulai dari satu jam hingga tiga puluh hari. Hal ini menjadikan model tidak hanya relevan untuk kebutuhan *trading intraday*, tetapi juga mampu mendukung perencanaan investasi jangka menengah hingga bulanan.

Dengan demikian, penelitian ini menawarkan kontribusi yang signifikan melalui integrasi multi-sumber data, resolusi temporal yang lebih granular, serta pengembangan arsitektur model hibrida yang secara eksplisit disesuaikan untuk prediksi *multi-horizon*. Tidak seperti penelitian sebelumnya yang cenderung terbatas pada satu jenis data dan hanya mencakup *horizon* jangka pendek dalam resolusi harian, pendekatan dalam studi ini memanfaatkan representasi sekuens temporal

jam-jam secara mendetail, serta menyertakan sepuluh *horizon* mulai dari satu jam hingga tiga puluh hari. *Gap* penelitian yang ditangani mencakup kekosongan dalam penggunaan metode *deep learning* berarsitektur konvolusi-rekursif dengan mekanisme perhatian kontekstual secara bersamaan untuk *forecasting* lintas-*horizon* dengan resolusi tinggi. Oleh karena itu, penelitian ini tidak hanya memperluas batasan metodologis yang telah ada, tetapi juga menjawab kebutuhan praktis akan sistem prediksi yang adaptif dan relevan untuk pengambilan keputusan investasi dalam berbagai kerangka waktu.

IV. METODOLOGI

A. Dataset Penelitian

Dalam penelitian ini, data yang digunakan mencakup tiga jenis utama: makroekonomi, *on-chain*, dan *off-chain*. Data diperoleh melalui proses penambangan data (*data mining*) dari berbagai sumber terpercaya, baik secara manual maupun otomatis. Secara khusus, data *off-chain* dan makroekonomi ditambang secara real time menggunakan API, memungkinkan pengambilan data terkini dengan frekuensi tinggi. Sementara itu, data *on-chain* ditambang dari *platform* penyedia metrik *blockchain* melalui unduhan berkala. Berikut adalah rincian jenis data, variabel, serta metode penambangannya yang digunakan dalam penelitian ini:

TABEL I.

JENIS DATA, VARIABEL, DAN SUMBER DATASET YANG DIGUNAKAN DALAM PENELITIAN

No	Kategori	Variabel	Sumber Data	Metode Akuisisi	Timeframe	Frekuensi
1	On-Chain	<i>HashRate, HashRate30d, AdrActCnt, TxCnt, TxTfrValAdjUSD, FeeMeanUSD, FeeTotUSD, CapMVRVCur, NVTAdj, SplyAct1d, SplyAct7d, SplyAct30d, IssCntPctDay, FlowInExUSD, FlowOutExUSD</i>	CoinMetrics	Manual Download	2017 - Sekarang	Per hari
2	Off-Chain	<i>open, high, low, close, volume, close_time, quote_asset_volume, num_trades, taker_buy_base_vol, taker_buy_quote_vol, fundingRate, is_futures_active</i>	Binance API	Scraping via API Binance	2017 - Sekarang	Per jam
3	Makroekonomi	<i>nasdaq_composite, qqc_etf, oil_price_brent, oil_price_wti, gold_price_usd_ars, usd_try, vix_index, 10y_treasury_yield</i>	Yahoo Finance (yfinance)	Scraping API yfinance	2017 - Sekarang	Per hari
		<i>core_pce, cpi_us, dxy_data, estimated_global_m2_us_m2, fed_balance_sheet, fed_funds_rate</i>	FRED (Federal Reserve Economic Data)	Manual download / API	2017 - Sekarang	Per bulan

B. Preprocessing Data

Preprocessing bertujuan untuk memastikan kualitas dan konsistensi data sebelum digunakan dalam model:

1) Resampling dan Sinkronisasi

Resampling dan Sinkronisasi: Data *off-chain* yang tersedia pada resolusi 1 jam disinkronkan dengan menggunakan fungsi *floor('H')* dan menghapus duplikat. Data *on-chain* yang

memiliki frekuensi harian/mingguan/bulanan di-*forward fill intraday*, dan data makroekonomi disematkan pada pukul 00:00 UTC, serta disesuaikan dengan waktu penutupan pasar (misal, *Nasdaq/QQQ* pada pukul 21:00 UTC).

2) Penanganan Missing Value

Penanganan *Missing Values*: Data yang hilang diisi menggunakan metode *forward fill* untuk makroekonomi dan *on-chain*, sementara volume perdagangan yang hilang diisi dengan 0.

Dalam penelitian ini, dataset dibagi menjadi tiga bagian: 95% (64223 baris data) digunakan sebagai data pelatihan (*training data*) untuk membangun model, 3% (2028 baris data) sebagai data validasi (*validation data*) untuk mengevaluasi performa model, dan 2% (1353 baris data) sebagai data pengujian (*testing data*) untuk menyetel parameter model agar tidak *overfitting*. Pembagian ini dilakukan secara kronologis untuk menjaga konsistensi temporal data.

C. Pemodelan (CNN→Bi-LSTM→MHA + Horizon Embed)

1) Pembentukan Sekuens Multi-Horizon

Dataset yang telah melalui tahap pra-pemrosesan diubah menjadi bentuk sekuens dengan pendekatan *sliding window* berdurasi 48 jam (*window size* = 48). Setiap jendela berisi urutan 48 titik data historis dari seluruh variabel prediktor yang digunakan untuk memprediksi perubahan harga (*delta-price*) Bitcoin pada sepuluh *horizon* waktu: 1 jam, 2 jam, 3 jam, 6 jam, 12 jam, 1 hari, 3 hari, 7 hari, 15 hari, dan 30 hari.

Untuk setiap *horizon* h , target didefinisikan sebagai perubahan relatif harga terhadap harga penutupan terakhir pada jendela input:

$$\Delta_h = \frac{P_{t+h} - P_t}{P_t + \epsilon}$$


P_t adalah harga penutupan pada akhir jendela input, P_{t+h}

adalah harga aktual pada *horizon* h , dan $\epsilon = 10^{-8}$ digunakan untuk menghindari pembagian nol.

Pendekatan ini memungkinkan model mempelajari dinamika perubahan harga yang telah dinormalisasi, sehingga prediksi dapat dikonversi kembali menjadi harga absolut pada tahap evaluasi:

$$P_{t+h} = P_t \times (1 + \Delta_{t,h})$$

2) Arsitektur Model Multihorizon LSTM-Attention



Gambar 1. Arsitektur Model Multihorizon LSTM-Attention

Model yang digunakan adalah *MultiHorizonModel*, yaitu arsitektur hibrid yang menggabungkan ekstraksi fitur lokal, pemodelan sekuens, dan mekanisme perhatian kontekstual (*contextual attention*), serta *embedding* khusus untuk setiap *horizon* prediksi. Arsitektur ini terdiri dari beberapa komponen utama:

- Lapisan Konvolusional 1D (Conv1D dengan dilasi 64 filter)
 - Berfungsi mengekstraksi pola fluktuasi lokal (*local patterns*) dari deret waktu multi-variabel.

- Dilasi (*dilation rate*) = 2 digunakan untuk memperluas receptive field tanpa meningkatkan ukuran kernel.
- b) *Bidirectional Long Short-Term Memory* (Bi-LSTM)
 - Memodelkan dependensi temporal baik ke arah masa lalu (*backward*) maupun masa depan (*forward*) dalam jendela input.
 - Dimensi keluaran total: 256 unit (128 per arah).
- c) *Layer Normalization*
 - Menormalkan distribusi aktivasi antar fitur untuk stabilitas pelatihan dan konvergensi yang lebih cepat.
- d) *Multi-Head Attention* (MHA)
 - Menghitung bobot perhatian antar langkah waktu sehingga model dapat fokus pada titik-titik historis yang paling relevan terhadap prediksi.
 - Menggunakan 4 attention heads untuk menangkap berbagai jenis pola hubungan temporal.
- e) *Adaptive Average Pooling*
 - Mereduksi keluaran sekuens menjadi vektor representasi tunggal per sampel, menjaga informasi ringkas yang telah diperkaya konteksnya.
- f) *Horizon Embedding*
 - Embedding layer berukuran 8 dimensi yang mewakili identitas masing-masing *horizon* prediksi.
 - Memungkinkan tiap *horizon* mempelajari bias temporal yang unik.
- g) *Multi-Head Output Layers*
 - Satu prediction head untuk setiap *horizon*.
 - Struktur tiap head: Linear(256 + d_emb → 64) → ReLU → Dropout(0.2) → Linear(64 → 1).

3) Strategi Pelatihan

Proses pelatihan model *MultiHorizonModel* dilaksanakan dalam dua fase, dengan tujuan mengoptimalkan seluruh parameter *trainable* dari arsitektur secara *end-to-end*. Optimisasi dilakukan menggunakan algoritma *Adam* dengan laju pembelajaran awal sebesar 1×10^{-3} dan fungsi kerugian *HuberLoss* ($\delta = 1$). Setiap *horizon* prediksi (h) diberi bobot kerugian linier yang meningkat dari *horizon* terpendek ke *horizon* terpanjang untuk memastikan prioritas akurasi jangka pendek tetap terjaga, sejalan dengan peran *horizon intraday* sebagai sistem peringatan dini kebijakan.

$$L = \frac{1}{H} \sum_{h=1}^H \omega_h \text{Huber}(\hat{\Delta}_{t,h}, \Delta_{t,h})$$

a) Fase 1 – Tuning dan Validasi

Pada fase ini, model dilatih menggunakan data latih dan divalidasi pada data validasi dengan mekanisme *early stopping* (*patience* = 3 *epoch*) berdasarkan nilai *validation loss*. Seluruh parameter *trainable* dioptimalkan tanpa melakukan *freezing* pada lapisan tertentu. Parameter yang dioptimalkan meliputi:

- Conv1D (12.352 parameter) : Kernel dan bias konvolusi 1-dimensi untuk ekstraksi pola lokal.
- Bi-LSTM (198.656 parameter) : Bobot dan bias *input*, *forget*, *cell*, dan *output gate* untuk arah *forward* dan *backward*.
- *Layer Normalization* (512 parameter) : Parameter *scale* dan *shift* untuk stabilisasi distribusi aktivasi.
- *Multi-Head Attention* (263.168 parameter) : Bobot proyeksi *query*, *key*, *value*, serta proyeksi keluaran.
- *Horizon Embedding* (80 parameter) : Vektor *embedding* berdimensi 8 untuk representasi identitas *horizon*.

- *Output Heads* – 10 *horizon* (170.250 parameter) : Bobot dan bias pada dua lapisan linear ($256 + d_emb \rightarrow 64$, dan $64 \rightarrow 1$) untuk setiap *horizon*.

b) Fase 2 – Pelatihan Ulang Final

Bobot terbaik hasil Fase 1 dimuat ulang, kemudian model dilatih ulang menggunakan gabungan data latih dan validasi selama 5 *epoch* penuh tanpa *early stopping*. Proses ini bertujuan memanfaatkan seluruh data historis untuk meningkatkan generalisasi sebelum evaluasi pada data uji. Prediksi yang dihasilkan model berbentuk perubahan harga relatif $\hat{\Delta}_{t,h}$, yang kemudian dikonversi kembali menjadi harga absolut menggunakan rumus:

$$\hat{P}_{t,h} = P_t \times (1 + \hat{\Delta}_{t,h})$$

Kinerja dievaluasi menggunakan *Root Mean Squared Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE) pada setiap *horizon* prediksi. Seluruh parameter diinisialisasi menggunakan default initialization PyTorch dengan *requires_grad=True*. Nilai acak diatur menggunakan *random seed* = 42 untuk Torch dan NumPy. Daftar lengkap nama parameter PyTorch dan jumlahnya dilampirkan dalam bentuk CSV pada lampiran penelitian, untuk mendukung replikasi eksperimen.

4) Rasionalisasi desain

Berikut ini merupakan rasionalisasi *desain multi-horizon LSTM-Attention*:

- a) Conv1D dilated → Efektif menangkap *local patterns* dari metrik *on-chain*, *off-chain*, dan makroekonomi.
- b) Bi-LSTM → Menangkap hubungan jangka panjang dan memanfaatkan konteks sebelum dan sesudah titik waktu.
- c) MHA → Memberikan fleksibilitas pada model untuk fokus pada titik-titik historis paling berpengaruh.
- d) *Horizon embedding* → Menghindari *information leakage* antar *horizon* dengan memberikan konteks spesifik pada setiap *output head*.
- e) *Weighted loss* → Memastikan akurasi *horizon* pendek (penting untuk *early warning*) tetap prioritas, tanpa mengabaikan *horizon* menengah-panjang.

V. ANALISIS HASIL EKSPERIMEN

Pada bab ini akan dipaparkan secara sistematis hasil eksperimen akhir dari model prediksi *multi-horizon*, meliputi metrik RMSE dan MAPE untuk setiap *horizon*, norma bobot Conv1D per fitur, serta daftar fitur teratas berdasarkan analisis SHAP.


A. Konfigurasi Eksperimen

Eksperimen dibagi menjadi dua fase utama. Pada fase pertama dilakukan *tuning hyperparameter* dan penerapan *early stopping* untuk menemukan konfigurasi pembelajaran yang optimal. Model dioptimalkan menggunakan Adam dengan laju pembelajaran sebesar 1×10^{-3} . Fungsi kerugian yang dipakai adalah *HuberLoss* ($\delta = 1$) dengan pemberian bobot linier yang meningkat dari *horizon* pertama hingga *horizon* terakhir.

Setelah fase tuning selesai, fase kedua dimulai dengan memuat ulang model terbaik dan melatih ulang menggunakan gabungan data training dan validasi untuk memaksimalkan pemanfaatan seluruh data historis. Pada fase ini model dijalankan selama 5 *epoch* penuh tanpa *early stopping*, dengan tujuan mengevaluasi kinerja akhir. Metode evaluasi yang

digunakan adalah perhitungan *Root Mean Squared Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE) pada data test untuk setiap *horizon* prediksi.

B. Kurva Training dan Validation Loss



Gambar 2. Kurva Training dan Validation Loss

Berdasarkan kurva pelatihan, *training loss* menurun stabil dari 0.0060 pada epoch pertama menjadi 0.0013 pada epoch ketujuh, menunjukkan proses pembelajaran yang terkendali, sementara *validation loss* mencapai titik terendah 0.0014 pada epoch kedua sebelum meningkat kembali, menandakan awal gejala *overfitting*; dengan penerapan *early stopping* dan *patience* tertentu, pelatihan dihentikan pada epoch kelima namun bobot terbaik diambil dari epoch kedua untuk memastikan performa generalisasi optimal, sehingga model mampu menghasilkan sinyal volatilitas intraday yang andal, konsisten, dan tidak sensitif terhadap *noise* jangka pendek dalam mendukung kebijakan investasi berbasis sistem peringatan dini.

C. Final RMSE & MAPE per Horizon

TABEL II.

JENIS DATA, VARIABEL, DAN SUMBER DATASET YANG DIGUNAKAN DALAM PENELITIAN

Horizon	CNN→Bi-LSTM→MHA + Horizon Embed	
	RMSE	MAPE (%)
1 Jam	566.74	0.46
2 Jam	687.32	0.55
3 Jam	783.00	0.63
6 Jam	1046.50	0.86
12 Jam	1774.11	1.59
1 Hari	2283.26	1.91
3 Hari	5438.38	4.79
7 Hari	6488.26	5.54
15 Hari	6898.91	5.85
30 Hari	14795.29	14.12

1) Horizon 1–3 Jam

Pada *horizon* ultra-pendek, model meraih MAPE di bawah 0,65% dengan RMSE antara 566.74 dan 783.00. Hasil ini menunjukkan keandalan tinggi untuk sinyal *intraday*: pelaku pasar institusional dan regulator dapat menggunakan ramalan 1–3 jam untuk menyiapkan intervensi cepat, misalnya menyesuaikan likuiditas pasar kripto atau merilis peringatan otomatis saat terjadi lonjakan aktivitas yang tidak biasa.

2) Horizon 6–24 Jam

Ketika prediksi melebar ke 6 dan 12 jam, MAPE naik ke 0,86% dan 1,59%. Kenaikan moderat ini masih berada dalam rentang yang dapat diakomodasi oleh penyesuaian kebijakan harian atau strategi manajemen risiko jangka pendek. Sementara itu, untuk *horizon* 1 hari dengan MAPE 1,91%, model masih relevan digunakan sebagai masukan pendukung dalam perencanaan kebijakan atau evaluasi pasar sebelum penetapan keputusan strategis.

3) Horizon 3–30 Hari

Pada *horizon* menengah (3–7 hari), MAPE melonjak ke 4,79% dan 5,54%, menandakan semakin pentingnya faktor fundamental jangka panjang. Untuk *horizon* 15 hari (5,85%) dan 30 hari (14,12%), error yang relatif tinggi mencerminkan volatilitas makro dan dinamika pasar digital jangka panjang. Dalam konteks alokasi cadangan devisa, hasil ini merekomendasikan agar output 30-hari dipadukan dengan simulasi makroekonomi dan scenario analysis sebelum digunakan sebagai dasar keputusan alokasi aset.

D. Norma Bobot Conv1D per Fitur

Sub-bab ini menjabarkan norma absolut bobot lapisan Conv1D untuk setiap fitur input, sebagai dasar identifikasi variabel yang paling banyak berkontribusi pada ekstraksi representasi awal.

TABEL III.
HASIL BOBOT SETIAP FITUR

Fitur	Nor ma	Fitur	Nor ma
<i>vix_index</i>	21.99	<i>NVTAdj</i>	10.77
<i>FeeMeanUSD</i>	25.43	<i>SplyAct1d</i>	11.47
<i>FlowInExUSD</i>	18.41	<i>SplyAct7d</i>	14.42
<i>usd_ars</i>	16.23	<i>SplyAct30d</i>	17.89
<i>gold_price</i>	15.78	<i>IssContPctDay</i>	10.84
<i>google_trends_bitc oin</i>	13.94	<i>FlowOutExUSD</i>	12.58
<i>CapMVRVCur</i>	16.62	<i>open</i>	13.15
<i>nasdaq_composite</i>	12.77	<i>high</i>	13.10
<i>10y_treasury_yield</i>	13.94	<i>low</i>	14.27
<i>fundingRate</i>	9.01	<i>close</i>	13.40
<i>is_futures_active</i>	8.85	<i>volume</i>	19.75
<i>HashRate30d</i>	11.61	<i>quote_asset_volu me</i>	15.43
<i>HashRate</i>	10.61	<i>num_trades</i>	13.74

<i>AdrActCnt</i>	12.19	<i>taker_buy_base_vol</i>	18.91
<i>TxCnt</i>	14.26	<i>taker_buy_quote_vol</i>	14.98
<i>TxTfrValAdjUSD</i>	13.39		

Pada tahap awal pemrosesan data, lapisan konvolusional satu dimensi (*Conv1D*) berperan penting dalam mengekstraksi representasi awal dari setiap fitur input. Dalam konteks deret waktu, *Conv1D* tidak hanya melakukan pemetaan spasial, tetapi juga menghasilkan rangkuman temporal yang menangkap pola fluktuatif lokal yang dianggap signifikan oleh model. Besarnya norma bobot pada masing-masing saluran *Conv1D* mencerminkan intensitas perhatian model terhadap fitur-fitur tersebut pada tahap awal pemrosesan sebelum diteruskan ke lapisan sekuensial seperti LSTM dan *attention*.

Analisis norma bobot *Conv1D* mengindikasikan bahwa beberapa fitur memiliki peran yang sangat dominan sejak awal. Misalnya, *FeeMeanUSD* (dengan norma sebesar 25,43) dan *FlowInExUSD* (18,41) menunjukkan nilai tertinggi, yang mengindikasikan bahwa rata-rata biaya transaksi serta arus masuk-keluar modal ke bursa kripto merupakan sinyal awal yang paling berpengaruh dalam mengidentifikasi gejala volatilitas intraday. Hal ini sejalan dengan pemahaman pasar bahwa lonjakan biaya transaksi dan volume arus modal sering kali menjadi indikator tekanan beli atau jual yang muncul secara tiba-tiba. Dengan demikian, fitur-fitur tersebut bertindak sebagai filter awal yang efektif untuk mendeteksi anomali pasar secara real-time.

Selain itu, variabel seperti *vix_index* (21,99), yang merepresentasikan indeks volatilitas pasar saham Amerika Serikat, juga memiliki norma bobot yang tinggi. Ini menunjukkan bahwa model secara implisit menangkap korelasi antara dinamika pasar ekuitas global dan fluktuasi harga aset kripto. Fenomena ini menguatkan argumentasi bahwa perubahan sentimen dan psikologi pasar global dapat merembes ke pasar digital, dan dengan demikian dapat dijadikan indikator makro untuk peringatan sistemik. Dalam konteks kebijakan moneter, sinyal semacam ini berpotensi dimanfaatkan oleh lembaga keuangan negara sebagai pemicu diskusi kebijakan mendadak, termasuk evaluasi suku bunga antar hari ketika terjadi lonjakan volatilitas yang tak biasa.

Di sisi lain, sejumlah metrik *on-chain* seperti *CapMVRVCur* (16,62) dan *SplyAct30d* (17,89) juga menunjukkan nilai norma yang signifikan. Kepercayaan model terhadap variabel ini menunjukkan bahwa kapitalisasi pasar relatif terhadap nilai realisasi (MVRV) serta suplai aktif selama 30 hari berfungsi sebagai indikator kesehatan jaringan yang valid, khususnya untuk perencanaan alokasi cadangan devisa dalam jangka menengah. Misalnya, penurunan drastis pada suplai aktif 30 hari dapat dipandang sebagai sinyal penurunan partisipasi jangka panjang, yang pada gilirannya mendorong pengambil kebijakan untuk mempertimbangkan strategi diversifikasi aset misalnya dengan menambah porsi cadangan dalam bentuk emas atau obligasi.

Sebaliknya, fitur seperti *is_futures_active* (8,85) dan *fundingRate* (9,01) tercatat memiliki norma bobot yang relatif rendah pada lapisan *Conv1D*. Temuan ini menyiratkan bahwa informasi dari pasar derivatif seperti *futures* cenderung tidak

dapat ditangkap secara optimal hanya melalui pola lokal. Oleh karena itu, interpretasi terhadap fitur-fitur tersebut lebih menonjol pada lapisan yang lebih tinggi, yakni *attention mechanism*, yang mampu memproses konteks sekuensial dan memperkuat sinyal berdasarkan dinamika temporal yang lebih kompleks. Secara konseptual, hal ini membedakan dua kategori fitur: pertama, sinyal makro-likuiditas seperti *fee*, arus modal, dan volatilitas global yang langsung terdeteksi melalui konvolusi awal; dan kedua, sinyal derivatif yang membutuhkan pemrosesan lebih lanjut untuk mengungkap relevansinya secara temporal.

Dengan demikian, analisis norma bobot *Conv1D* tidak hanya memberikan wawasan tentang pentingnya fitur dalam proses ekstraksi awal, tetapi juga mengarahkan pemahaman terhadap jalur informasi yang ditempuh oleh model dalam membangun representasi akhir untuk prediksi harga *multi-horizon* yang akurat dan kontekstual.

E. Top-5 Fitur SHAP per Horizon

TABEL IV.
HASIL SHAP SETIAP JAM

<i>Horizon</i>	1 jam	2 jam	3 jam	6 jam	12 jam
1	<i>is_futures_active</i>	<i>is_futures_active</i>	<i>is_futures_active</i>	<i>gold_price</i>	<i>gold_price</i>
2	<i>fundingRate</i>	<i>fundingRate</i>	<i>fundingRate</i>	<i>usd_ars</i>	<i>HashRate30d</i>
3	<i>taker_buy_quote_vol</i>	<i>taker_buy_quote_vol</i>	<i>taker_buy_quote_vol</i>	<i>HashRate30d</i>	<i>usd_ars</i>
4	<i>taker_buy_base_vol</i>	<i>taker_buy_base_vol</i>	<i>taker_buy_base_vol</i>	<i>close</i>	<i>close</i>
5	<i>num_trades</i>	<i>num_trades</i>	<i>num_trades</i>	<i>low</i>	<i>low</i>

TABEL V.
HASIL SHAP SETIAP HARI

<i>Horizon</i>	1 hari	3 hari	7 hari	15 hari	30 hari
1	<i>gold_price</i>	<i>gold_price</i>	<i>gold_price</i>	<i>gold_price</i>	<i>gold_price</i>
2	<i>usd_ars</i>	<i>usd_ars</i>	<i>HashRate30d</i>	<i>HashRate30d</i>	<i>HashRate30d</i>
3	<i>nasdaq_composite</i>	<i>nasdaq_composite</i>	<i>usd_ars</i>	<i>FlowInExUSD</i>	<i>usd_ars</i>

4	<i>low</i>	<i>HashRate30d</i>	<i>nasdaq_composite</i>	<i>usd_ars</i>	<i>HashRate</i>
5	<i>HashRate30d</i>	<i>fed_funds_rate</i>	<i>fed_funds_rate</i>	<i>fed_funds_rate</i>	<i>close</i>

Analisis SHAP menunjukkan bahwa setiap *horizon* waktu dalam prediksi harga Bitcoin dipengaruhi oleh kumpulan variabel yang berbeda, mencerminkan perbedaan karakteristik volatilitas serta faktor fundamental yang relevan pada masing-masing skala waktu.

Untuk *horizon* jangka sangat pendek, yaitu 1 hingga 3 jam, model cenderung sangat bergantung pada variabel yang merepresentasikan aktivitas transaksi *real-time* dan dinamika pasar derivatif. Fitur-fitur seperti volume pembelian oleh taker (*taker_buy_base_vol* dan *taker_buy_quote_vol*), jumlah transaksi (*num_trades*), serta metrik yang terkait dengan pendanaan dan keaktifan pasar *futures* (*fundingRate* dan *is_futures_active*) muncul sebagai determinan utama. Ketergantungan ini menunjukkan bahwa model sensitif terhadap fluktuasi likuiditas dan perubahan sentimen pasar yang berlangsung secara cepat, menjadikannya relevan untuk sistem peringatan dini (*early warning*) dalam konteks perdagangan *intraday*.

Pada *horizon* menengah, yaitu antara 6 hingga 24 jam, fokus model mulai bergeser ke indikator yang mencerminkan stabilitas ekonomi makro dan kekuatan jaringan *blockchain*. Harga emas (*gold_price*) digunakan sebagai proksi sentimen risiko global, sementara nilai tukar dolar Amerika Serikat terhadap mata uang negara berkembang (misalnya *usd_ars*) dan rata-rata kekuatan komputasi jaringan selama 30 hari (*HashRate30d*) menjadi variabel yang semakin dominan. Pergeseran ini menandakan bahwa seiring dengan bertambahnya *horizon* waktu, sinyal berbasis transaksi jangka pendek mulai kehilangan pengaruh, digantikan oleh indikator yang lebih stabil dan mencerminkan kondisi fundamental ekonomi serta teknologi jaringan.

Sementara itu, pada *horizon* jangka panjang, yaitu antara satu hari hingga tiga puluh hari, model memperlihatkan peningkatan ketergantungan terhadap variabel makroekonomi dan indikator arus modal. Tingkat suku bunga acuan Federal Reserve (*fed_funds_rate*), arus masuk dan keluar modal ke dalam bursa aset kripto (*FlowInExUSD*), serta indikator jaringan seperti *HashRate30d* dan suplai aktif jangka panjang (*SplyAct30d*) menjadi faktor utama dalam proses prediksi. Meskipun demikian, harga emas dan kekuatan dolar AS tetap mempertahankan relevansinya hingga *horizon* bulanan. Komposisi fitur ini menegaskan bahwa prediksi harga dalam jangka panjang membutuhkan pemahaman mendalam terhadap kebijakan moneter global, dinamika arus modal internasional, serta kondisi fundamental dari jaringan *blockchain* itu sendiri. Ketiganya merupakan komponen strategis dalam konteks pengelolaan risiko sistemik, perencanaan investasi jangka menengah, dan penyusunan kebijakan makroekonomi berbasis data.

VI. KESIMPULAN DAN SARAN

A. Kesimpulan

Penelitian ini membuktikan bahwa integrasi data *off-chain*, *on-chain*, dan indikator makroekonomi ke dalam arsitektur hibrida CNN → Bi-LSTM → *Multi-Head Attention* dengan *horizon embedding* mampu memberikan kinerja prediksi harga Bitcoin *multi-horizon* yang kompetitif.

Pada *horizon* ultra-pendek (1–3 jam), model mencapai MAPE <0,65% dan RMSE 566–791, menunjukkan kemampuan memberikan sinyal *intraday* yang presisi untuk deteksi dini perubahan pasar. Pada *horizon* menengah (6–24 jam), MAPE tetap di bawah 2%, menandakan relevansi untuk mendukung strategi manajemen risiko harian atau pengambilan keputusan berbasis data jangka pendek.

Pada *horizon* panjang (3–30 hari), akurasi menurun hingga MAPE 14,12%, mencerminkan kompleksitas faktor fundamental dan volatilitas makroekonomi jangka panjang. Temuan ini mengindikasikan bahwa prediksi *horizon* panjang sebaiknya digunakan bersama analisis skenario makroekonomi untuk meningkatkan keandalan.

Analisis Conv1D *weight norms* mengungkap bahwa fitur seperti *FeeMeanUSD*, *FlowInExUSD*, dan *vix_index* dominan dalam membentuk sinyal awal *intraday*, sementara analisis SHAP menunjukkan pergeseran variabel penting dari indikator transaksi jangka pendek menuju indikator makroekonomi dan fundamental jaringan untuk *horizon* yang lebih panjang. Hasil ini menegaskan relevansi pemodelan multi-sumber dan *multi-horizon* untuk memahami dinamika aset kripto dalam berbagai skala waktu.

B. Rekomendasi

1) Pengembangan Sistem Peringatan Dini Berbasis

Berdasarkan hasil penelitian, disarankan pengembangan sistem peringatan dini (*Digital Asset Early Warning System*) berbasis prediksi *horizon* ultra-pendek (1–3 jam) untuk mendeteksi lonjakan volatilitas pasar aset digital secara real-time, dengan memanfaatkan variabel dominan seperti *FeeMeanUSD*, *FlowInExUSD*, dan *vix_index* yang terbukti menjadi indikator awal tekanan pasar. Sistem ini perlu mengintegrasikan data *off-chain*, *on-chain*, dan indikator makroekonomi ke dalam model hibrida CNN → Bi-LSTM → *Multi-Head Attention*, serta menerapkan ambang deteksi berbasis residual dan konfluensi indikator untuk memicu notifikasi otomatis ketika deviasi prediksi melebihi batas yang ditetapkan. Penerapan sistem ini memungkinkan pelaku pasar institusional, manajer risiko, dan regulator mengambil langkah mitigasi cepat, seperti penyesuaian likuiditas, aktivasi *circuit breaker*, atau penerapan strategi lindung nilai *intraday*, sekaligus menyediakan dukungan pengambilan keputusan yang berbasis data dan responsif terhadap dinamika pasar kripto yang sangat fluktuatif.

2) Pemanfaatan Prediksi Horizon Menengah untuk Perencanaan Taktis

Untuk *horizon* prediksi 6–24 jam dengan akurasi relatif stabil (MAPE < 2%), disarankan pemanfaatannya sebagai salah satu komponen input dalam perencanaan kebijakan dan strategi investasi jangka pendek, khususnya untuk penyesuaian parameter risiko dan likuiditas harian. Berdasarkan analisis SHAP, variabel dominan pada *horizon* ini meliputi *gold_price* sebagai indikator sentimen risiko global, nilai tukar USD terhadap mata uang negara berkembang (*usd_ars*) sebagai proksi arus modal internasional, dan *HashRate30d* yang mencerminkan kekuatan fundamental jaringan *blockchain*.

Integrasi prediksi ini dapat dilakukan oleh regulator untuk menyusun kebijakan likuiditas harian atau pembatasan *leverage* derivatif, sementara manajer risiko dan *hedge fund* dapat memanfaatkannya untuk optimisasi portofolio, penyesuaian strategi lindung nilai (*hedging*), serta sinkronisasi alokasi aset berbasis tren harian. Pendekatan ini memberikan keseimbangan antara reaktivitas terhadap perubahan pasar dan stabilitas analisis, sehingga relevan sebagai panduan pengambilan keputusan taktis berbasis data.

3) Integrasi Prediksi Horizon Panjang dengan Analisis Skenario

Output prediksi *horizon* 3–30 hari sebaiknya diintegrasikan dengan simulasi skenario makroekonomi untuk menguji sensitivitas proyeksi terhadap perubahan variabel kunci seperti suku bunga acuan, harga emas, dan kekuatan USD. Hasil prediksi juga perlu diuji melalui *stress testing* dengan memberikan guncangan ekstrem pada indikator dominan seperti *fed_funds_rate*, *FlowInExUSD*, *HashRate30d*, dan *SplyAct30d* guna mengukur potensi kerugian dan kebutuhan likuiditas dalam kondisi pasar yang tidak stabil. Selanjutnya, integrasikan hasil tersebut ke dalam model portofolio agar alokasi aset dapat disesuaikan secara proporsional terhadap profil risiko dan tujuan investasi. Pendekatan ini memastikan prediksi jangka menengah–panjang tidak digunakan secara mentah, tetapi diperkaya dengan uji ketahanan dan optimisasi portofolio sehingga keputusan investasi lebih adaptif terhadap ketidakpastian eksternal.

4) Eksplorasi Strategi Inovatif dan Instrumen Hijau

Sebagai pengembangan lebih lanjut dari temuan model pada *horizon* panjang, disarankan penerapan konsep Adaptive Reserve Allocation, yaitu penyesuaian proporsi cadangan divisa secara dinamis berdasarkan indikator eksternal seperti *fed_funds_rate*, *FlowInExUSD*, *HashRate30d*, dan *SplyAct30d* untuk meningkatkan ketahanan portofolio terhadap volatilitas makro dan perubahan arus modal. Selain itu, Regulatory Sandbox untuk instrumen inovatif seperti *green crypto bonds* dapat digunakan sebagai ruang uji terbatas guna mengevaluasi kelayakan dan risiko produk keuangan berbasis aset kripto yang mendukung proyek hijau, sambil memanfaatkan prediksi *horizon* panjang untuk memantau dan menyesuaikan strategi mitigasi risiko sebelum implementasi penuh.

REFERENSI

- [1] R. Bourday, I. Aatouchi, M. Kerroum, and A. Zaaouat, "Cryptocurrency Forecasting Using Deep Learning Models: A Comparative Analysis," *HighTech and Innovation Journal*, 2024. doi: 10.28991/hij-2024-05-04-013.
- [2] Z. Wainwright, "A Closer Look at Bitcoin's Volatility," *Fidelity Digital Assets*, May 1, 2024. [Online]. Available: fidelitydigitalassets.com
- [3] Reuters, "Indonesia's FDI drops 6.95% y/y in Q2, biggest fall since 2020," *Reuters*, Jul. 29, 2025. [Online]. Available: <https://www.reuters.com/world/asia-pacific/indonesias-fdi-drops-695-yy-q2-biggest-fall-since-2020-2025-07-29> [Accessed: Aug. 10, 2025].
- [4] S. Baur, "Bitcoin and portfolio diversification: A portfolio optimization approach," *Sustainability*, vol. 14, no. 7, p. 282, 2022. [Online]. Available: <https://www.mdpi.com/1911-8074/14/7/282> [Accessed: Aug. 10, 2025].
- [5] M. O. Qarni and S. Gulzar, "Portfolio diversification benefits of alternative currency investment in Bitcoin and foreign exchange markets," *J. Financ. Innov.*, vol. 7, no. 17, pp. 1–17, 2021. [Online]. Available: <https://jfin-swufe.springeropen.com/articles/10.1186/s40854-021-00233-5> [Accessed: Aug. 10, 2025].
- [6] Dimensional Fund Advisors, "Uncorrelated assets: An important dimension of an optimal portfolio," *Perspectives*, 2023. [Online]. Available: https://www.aqr.com/Insights/Perspectives/Uncorrelated-Assets-An-Important-Dimension-of-an-Optimal-Portfolio-1_12 [Accessed: Aug. 10, 2025].
- [7] G. Demosthenous, C. Georgiou, and E. Polydorou, "From on-chain to macro: Assessing the importance of data source diversity in cryptocurrency market forecasting," *arXiv*, 2025. [Online]. Available: <https://arxiv.org/html/2506.21246>
- [8] H. Jung, J. Kim, and H. Lee, "Decoding Bitcoin: leveraging macro- and micro-factors in time series analysis for price prediction," *PeerJ Computer Science*, vol. 10, 2024. doi: 10.7717/peerj-cs.2314
- [9] S. Nakamoto, "Bitcoin: A Peer-to-Peer Electronic Cash System," 2008. [Online]. Available: <https://archive.org/details/BitcoinAPeer-to-PeerElectronicCashSystem>
- [10] A. M. Antonopoulos, *Mastering Bitcoin: Programming the Open Blockchain*, 2nd ed. O'Reilly Media, 2017. [Online]. Available: <https://github.com/bitcoinbook/bitcoinbook>
- [11] M. Ali, A. Nelson, R. Shea, and M. Freedman, "An Overview of Bitcoin and Blockchain Technology: Security, Regulations, and Volatility," in *2019 IEEE Symposium on Security and Privacy Workshops (SPW)*, 2019, pp. 168–175. doi: 10.1109/SPW.2019.00027.
- [12] M. G. Kondor, G. Pósfai, I. Csabai, and G. Vattay, "Do the rich get richer? An empirical analysis of the Bitcoin transaction network," *PloS One*, vol. 9, no. 2, e86197, 2014. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0086197>
- [13] S. Corbet, B. Lucey, A. Urquhart, and L. Yarovaya, "Cryptocurrencies as a Financial Asset: A Systematic Analysis," *International Review of Financial Analysis*, vol. 62, 2019, pp. 182–199. [Online]. Available: <https://doi.org/10.1016/j.irfa.2018.11.005>
- [14] D. G. Baur and B. M. Lucey, "Is Gold a Hedge or a Safe Haven? An Analysis of Stocks, Bonds and Gold," *Financial Review*, vol. 45, no. 2, pp. 217–229, 2010. doi: 10.1111/j.1540-6288.2010.00244.x
- [15] Z. Bodie, A. Kane, and A. J. Marcus, *Investments*, 10th ed. New York, NY, USA: McGraw-Hill Education, 2014.
- [16] A. Jayawardhana and S. Colombaro, "Portfolio diversification possibilities of cryptocurrency: Global evidence," *Applied Economics*, vol. 56, no. 47, pp. 5618–5633, 2023. doi: 10.1080/00036846.2023.2257928
- [17] OECD, "OECD Economic Outlook, Volume 2025 Issue 1: Indonesia," OECD Publishing, 2025. [Online]. Available: https://www.oecd.org/en/publications/2025/06/oecd-economic-outlook-volume-2025-issue-1_1fd979a8/full-report/indonesia_4c4ce2be.html
- [18] M. A. Kurniawan and A. Irawan, "Volatility Spillover Between Global and Indonesian Stock Markets: Evidence from GARCH-DCC Model," *Jurnal Ekonomi dan Bisnis*, vol. 24, no. 1, pp. 45–56, 2021. [Online]. Available: <https://ejournal.undip.ac.id/index.php/jeb/article/view/xyz>
- [19] I. Ahmed, M. Patoli, H. Ahmed, and S. Mahmood, "The Role of Blockchain Technology in Enhancing Transparency and Efficiency in Trade Finance," *The Critical Review of Social Sciences Studies*, vol. 3, no. 1, pp. 923–938, 2025. doi: 10.59075/p8pe5m18
- [20] S. de O. Santos Júnior, "Time-series modeling for consumer price index forecasting using ARIMA and neural network models: The case of Indonesian CPI," in *Proc. SCITEPRESS – Science and Technology Publications*, 2020. [Online]. Available: <https://www.scitepress.org/Papers/2020/103692>
- [21] A. Abdul Khaliq, "Global and country-specific geopolitical risks and exchange rate volatility: Evidence from Indonesia," *Jurnal Ekonomi Kuantitatif Terapan*, vol. 15, no. 2, pp. 226–236, 2022.
- [22] A. S. Siami-Namini and A. Siami Namin, "Forecasting economics and financial time series: ARIMA vs. LSTM," *arXiv*, 2018. [Online]. Available: <https://arxiv.org/abs/1803.06386>
- [23] G. E. P. Box, G. M. Jenkins, and G. C. Reinsel, *Time series analysis: Forecasting and control*, 5th ed. Wiley, 2015.
- [24] Y. You and X. Liu, "Forecasting short-run exchange rate volatility with monetary fundamentals: A GARCH-MIDAS approach," *Journal of Banking & Finance*, vol. 116, Art. no. 105849, 2020. doi: 10.1016/j.jbankfin.2020.105849

-
- [25] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997. doi: 10.1162/neco.1997.9.8.1735
 - [26] D. Omole and D. Enke, "Comparing LSTM, CNN-LSTM, and Temporal Convolutional Networks for Bitcoin price prediction," *Journal of Financial Technology*, vol. 8, no. 2, pp. 120–136, 2024.
 - [27] MDPI, "Temporal attention-enhanced stacking networks: Revolutionizing multi-step Bitcoin forecasting," *Journal of Financial Technology*, vol. 7, no. 1, pp. 2–14, 2023. [Online]. Available: <https://mdpi.com/2571-9394/7/1/2>
 - [28] M.-C. Lee, "Bitcoin trend prediction with attention-based deep learning models and technical indicators," *Systems*, vol. 12, no. 11, p. 498, 2024. doi: 10.3390/systems12110498
 - [29] P. L. Seabe, E. Pindza, C. R. B. Moutsinga, and M. Aphane, "Temporal attention-enhanced stacking networks: Revolutionizing multi-step Bitcoin forecasting," *Forecasting*, vol. 7, no. 1, p. 2, 2025. doi: 10.3390/forecast7010002
 - [30] A. Graves, "Speech recognition with deep recurrent neural networks," in 2013 IEEE Int. Conf. on Acoustics, Speech and Signal Processing (ICASSP), 2013, pp. 6645–6649. doi: 10.1109/ICASSP.2013.6638947
 - [31] A. Vaswani et al., "Attention is all you need," in *Advances in Neural Information Processing Systems*, 2017, pp. 5998–6008. doi: 10.48550/arXiv.1706.03762
 - [32] Z. Zhang, C. Jiang, and M. Lu, "Fusion of sentiment and market signals for Bitcoin forecasting: A SentiStack network based on a stacking LSTM architecture," *Big Data and Cognitive Computing*, vol. 9, no. 6, p. 161, 2025. doi: 10.3390/bdcc9060161

Lampiran:

1. Model dan Dataset

Link : [Link Model dan Dataset](#)



Keterangan Variabel

On-Chain Metrics (CoinMetrics, Harian)

(Menangkap dinamika jaringan & perilaku investor jangka pendek hingga menengah)

- HashRate & HashRate30d: Total daya komputasi jaringan Bitcoin (saat ini & rata-rata 30 hari). Semakin tinggi, menunjukkan keamanan jaringan; berguna untuk menilai stabilitas dalam model prediksi volatilitas.
- AdrActCnt (Active Addresses Count): Jumlah alamat unik yang aktif dalam transaksi. Indikator adopsi & aktivitas pasar; membantu menangkap lonjakan minat beli.
- TxCnt (Transaction Count): Total transaksi per hari. Mencerminkan aktivitas jaringan; korelasi dengan likuiditas dan fluktuasi harga intraday.
- TxTfrValAdjUSD (Transfer Value Adjusted USD): Nilai transfer harian dalam USD, disesuaikan fee. Menunjukkan besaran arus modal; penting untuk memodelkan momentum pasar.
- FeeMeanUSD & FeeTotUSD: Biaya transaksi rata-rata dan total. Indikator kemacetan jaringan; fee tinggi sering menjadi sinyal lonjakan permintaan.
- CapMVRVCur (Market Value to Realized Value): Rasio kapitalisasi pasar terhadap nilai realisasi. Menilai overbought/oversold; fitur kunci untuk horizon harian.
- NVTAdj (Network Value to Transactions Adjusted): Versi NVT yang diperbaiki; mengukur valuasi relatif aktivitas transaksi.
- SplyAct1d / 7d / 30d (Active Supply): Persentase suplai yang bergerak dalam 1, 7, atau 30 hari. Mengungkap pola distribusi kepemilikan (HODLer vs trader).
- IssContPctDay (Issuance Contribution Percentage): Persentase pasokan baru relatif hari sebelumnya. Menunjukkan suplai inflasi blok; mempengaruhi tekanan jual.

- FlowInExUSD & FlowOutExUSD: Arus masuk dan keluar Bitcoin ke/dari bursa, dalam USD. Indikator likuiditas dan potensi tekanan jual/beli.

Off-Chain Metrics (Binance API, Per Jam)

(Menyediakan data harga dan volume real-time untuk analisis teknikal multi-horizon)

- open / high / low / close: Harga pembukaan, tertinggi, terendah, dan penutupan setiap jam. Fondasi analisis teknikal (candlestick).
- volume: Volume perdagangan per jam; sinyal kekuatan tren.
- close_time: Waktu penutupan bar harga; penting untuk sinkronisasi data.
- quote_asset_volume: Total volume aset lawan (biasanya USDT); mengukur likuiditas pasangan BTC.
- num_trades: Jumlah transaksi eksekusi; indikator partisipasi pasar.
- taker_buy_base_vol / taker_buy_quote_vol: Volume taker buy (asiny) dan (kutipan); menggambarkan tekanan beli institusional.
- fundingRate: Biaya finansial per jam pada perpetual futures; menandakan sentimen derivatif.
- is_futures_active: Status pasar berjangka; mengonfirmasi likuiditas dan sentimen.

Indikator Makroekonomi

(Memberikan konteks eksternal untuk tren harga jangka panjang dan pengaruh kebijakan moneter global.)

a. Harian (Yahoo Finance)


- nasdaq_composite & qqq_etf: Indeks saham AS; pengaruh sentimen global terhadap aset berisiko.
- oil_price_brent & oil_price_wti: Harga minyak global; mempengaruhi inflasi dan aliran modal.
- gold_price: Harga emas; aset safe-haven untuk diversifikasi model jangka panjang.
- usd_ars & usd_try: Nilai tukar Dolar ke Peso Argentina dan Lira Turki; proxy tekanan mata uang emerging.
- vix_index: Indeks volatilitas S&P 500; sentimen risiko global.
- 10y_treasury_yield: Imbal hasil obligasi AS 10-tahun; indikator suku bunga jangka panjang.

b. Bulanan (FRED)


- core_pce & cpi_us: Indeks harga inti dan CPI AS; memproksikan inflasi global.
- dxy_data: Indeks Dolar AS; kekuatan USD terhadap mata uang utama.
- estimated_global_m2 & us_m2: M2 global dan AS; indikator likuiditas pasar.
- fed_balance_sheet: Ukuran neraca The Fed; kebijakan QE/QT.
- fed_funds_rate: Suku bunga acuannya; mempengaruhi biaya modal.

2. Grafik Hasil Pelatihan


2.1 Output RMSE & MAPE Horizon 1 jam




2.2 Output RMSE & MAPE Horizon 2 jam




2.3 Output RMSE & MAPE Horizon 3 jam




2.4 Output RMSE & MAPE Horizon 6 jam




2.5 Output RMSE & MAPE Horizon 12 jam




2.6 Output RMSE & MAPE Horizon 1 hari




2.7 Output RMSE & MAPE Horizon 3 hari



2.8 Output RMSE & MAPE Horizon 7 hari



2.9 Output RMSE & MAPE Horizon 15 hari



2.10 Output RMSE & MAPE Horizon 30 hari

