

Peningkatan Keandalan dan Efisiensi Token LLM pada Data Time Series melalui Pendekatan Verifikasi Deterministik

Ahmad Naufal Farras¹, Jeremy Mattathias Mboe², Mochammad Henry Alifian³, Dhany Arifianto⁴

¹Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember, Surabaya, 60111, email: 5054241038@student.its.ac.id

²Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember, Surabaya, 60111, email: 5054241012@student.its.ac.id

³Fakultas Teknologi Elektro dan Informatika Cerdas, Institut Teknologi Sepuluh Nopember, Surabaya, 60111, email: 5054241024@student.its.ac.id

⁴Fakultas Kedokteran dan Kesehatan, Institut Teknologi Sepuluh Nopember, Surabaya, 60111

Corresponding Author: Ahmad Naufal Farras

INTISARI — Model bahasa besar atau LLM unggul mengolah bahasa, tetapi lemah menalar atas angka. Karena itu model sering keliru ketika menganalisis data *time series*, misalnya menyebut tren, lokasi lonjakan, atau besaran kenaikan yang tidak sesuai data, dengan kalimat yang terdengar meyakinkan. Kekeliruan seperti ini berisiko pada bidang bertaruh tinggi seperti kesehatan dan pangan. Penelitian ini mengusulkan sebuah pendekatan penalaran *time series* yang *grounded*, artinya tiap langkah berpijak pada perhitungan nyata, dan sekaligus hemat *token*. Ada dua kontribusi. Pertama, sebuah *dataset* penalaran *time series* terverifikasi yang dibangun dari sumber publik nyata di Indonesia, yaitu harga pangan PIHPS Bank Indonesia, kasus penyakit Kementerian Kesehatan, cuaca BMKG, dan beban energi, lalu disimpan dalam format JSONL dengan lapisan penalaran yang tiap angkanya sudah dicek. Kedua, sebuah metode yang memasang LLM hasil *fine-tune* kelas Qwen2.5-7B dengan verifikator deterministik berbasis NumPy di luar model. LLM menuliskan penalaran sebagai urutan operasi dari pustaka tetap, bukan prosa bebas, lalu verifikator menghitung ulang tiap operasi atas deret asli dan membandingkannya dengan angka yang diklaim memakai toleransi gabungan absolut dan relatif. Metrik utamanya adalah skor *grounding*, yaitu persentase langkah penalaran yang angkanya tetap cocok saat dihitung ulang, dan dihitung tanpa LLM penilai. Pada uji awal, verifikator berhasil mereproduksi penalaran jujur pada deret kasus DBD mingguan dengan skor *grounding* 100 persen, dan menurunkan skor menjadi 66,7 persen ketika satu langkah dibuat berhalusinasi, yaitu mengklaim kenaikan 30 persen padahal 105 persen. Fondasi pustaka operasi, skema, dan verifikator sudah lolos 20 pengujian. Pembeda penelitian ini adalah penggabungan penalaran terverifikasi dan hemat token pada *time series* di atas data lokal yang dibangun sendiri.

KATA KUNCI: Penalaran *Time Series*, Skor *Grounding*, Verifikator Deterministik, *Chain-of-Thought*, Efisiensi *Token*, *Fine-tuning* LLM, QLoRA, Penalaran Neuro-Simbolik, *Data Mining*.

I. PENDAHULUAN

Data *time series* muncul di banyak keputusan penting, misalnya kasus penyakit tiap minggu, harga pangan tiap hari, dan beban listrik tiap jam. Selama ini pemakaian datanya lebih banyak diarahkan ke peramalan, yaitu menebak angka berikutnya. Padahal angka ramalan saja sering belum cukup untuk mengambil keputusan. Yang lebih dibutuhkan adalah tafsiran atas datanya, umpamanya menilai apakah kenaikan pada beberapa minggu terakhir menandakan wabah yang mulai terbentuk. Kemampuan menafsir semacam ini disebut penalaran, dan porsinya masih tertinggal dibanding peramalan [1].

Model bahasa besar atau LLM banyak dipakai sebagai antarmuka, tetapi lemah saat berhadapan dengan angka. Pada deret yang panjang, model cenderung menebak dari pola bahasa alih-alih menghitung, sehingga hasilnya bisa salah walau terdengar meyakinkan [1][2]. Sebagai contoh, untuk deret kasus mingguan 12, 15, 11, 14, 13, 18, 22, 19, 25, 31, 29, 38, 45, 52, 61, 78 dengan pertanyaan apakah ada indikasi wabah, jawaban yang benar adalah ada. Nilai dasar pada awal deret sekitar 13 kasus, empat minggu terakhir naik dari 38 ke 78 atau sekitar 105 persen, dan nilai akhirnya kira-kira enam kali nilai dasar. Pada kasus seperti ini model kerap keliru dalam tiga bentuk. Pertama, menutupi bahaya dengan menyimpulkan kasus stabil padahal sudah naik ke 78. Kedua, salah menunjuk lokasi lonjakan, umpamanya menyebut minggu keenam padahal nilainya hanya 18. Ketiga, salah menaksir besaran, umpamanya menyebut kenaikan sekitar 30 persen padahal mencapai ratusan persen.

Kekeliruan seperti itu berisiko karena kalimatnya tampak rapi. Pada bidang bertaruh tinggi seperti kesehatan dan pangan,

jawaban tanpa alasan yang bisa diperiksa tidak layak dipercaya. Karena itu penalaran perlu bersifat *grounded*, yaitu tiap langkahnya berpijak pada perhitungan nyata atas deret dan bisa diperiksa ulang, sehingga orang dapat menelusuri jalan pikirannya sebelum bertindak. Pendekatan ini juga menyatukan dua hal yang selama ini terpisah, yaitu metode statistik yang bisa menghitung tetapi tidak menjelaskan, dan LLM yang bisa menjelaskan tetapi tidak menghitung.

A. Kesenjangan Penelitian

Penalaran atas *time series* sedang ramai diteliti pada 2026, terlihat dari sejumlah naskah di ICLR 2026, revisi tolok ukur, dan survei khusus [2][5]. Ada pula temuan bahwa cara penalaran yang berhasil di soal matematika belum tentu bekerja pada deret waktu [1]. Arah penalaran yang bisa diverifikasi untuk *time series* memang sudah mulai dikerjakan [3], tetapi penalaran yang dihasilkan panjang dan boros *token*. Di sisi lain, riset penghematan *token* lewat pengaturan panjang penalaran menurut tingkat kesulitan sudah berkembang, tetapi masih terbatas pada soal matematika [4]. Sampai sekarang belum ada yang menyatukan keduanya untuk *time series*, dan belum ada *dataset* penalaran *time series* terverifikasi yang dibangun dari sumber lokal. Kami tidak mengklaim bidang ini belum tersentuh, tetapi gabungan penalaran terverifikasi dan hemat *token* di atas data lokal buatan sendiri memang belum pernah dikerjakan.

B. Kontribusi

Penelitian ini memberi tiga kontribusi. Pertama, sebuah *dataset*, yaitu korpus penalaran *time series* terverifikasi dari

sumber publik nyata di Indonesia, dalam format JSONL, dengan penalaran yang tiap langkahnya sudah dicek ke angka. Bagian ini menjadi kontribusi utama untuk kompetisi data mining karena usaha membangun datanya terlihat jelas. Kedua, sebuah metode, yaitu pemasangan LLM hasil *fine-tune* dengan verifikator deterministik di luar model, ditambah pengaturan panjang penalaran yang adaptif untuk menghemat *token*. Ketiga, sebuah metrik, yaitu skor *grounding* yang mengukur kejujuran penalaran terhadap angka dan dihitung tanpa LLM penilai. Kebaruannya bukan pada LLM, sebab LLM meminjam yang sudah ada lalu disetel ulang, melainkan pada data yang dibangun sendiri dan pada pasangan model dan verifikator yang membuat penalaran bisa diperiksa sekaligus hemat.

C. Rumusan Masalah

Empat pertanyaan penelitian diajukan. RQ1, seberapa sering model sekarang berhalusinasi saat menalar *time series*, terlihat dari skor *grounding* rendah meski jawaban kadang benar. RQ2, apakah metode kami menaikkan skor *grounding* tanpa menurunkan akurasi jawaban. RQ3, apakah penalaran adaptif kami lebih hemat *token* dibanding penalaran panjang pada akurasi setara. RQ4, komponen mana yang paling berpengaruh pada hasil.

II. TINJAUAN PUSTAKA

A. Penalaran atas Time Series

Model bahasa besar masih sulit menalar tanpa contoh tentang *time series*, dan penalaran yang panjang tidak selalu menaikkan mutu analisis deret waktu [1]. Tolok ukur multimodal untuk penalaran temporal memperlihatkan model masih gagal ketika harus menggabungkan angka dan teks [2]. Upaya lain mendorong penalaran yang lebih rumit atas *time series* pada LLM melalui pelatihan berbasis insentif [5]. Kumpulan karya ini menunjukkan bidangnya aktif tetapi belum tuntas.

B. Chain-of-Thought dan Program-of-Thought

Memunculkan langkah penalaran antara terbukti menaikkan hasil pada tugas rumit, tetapi langkah itu tetap berupa prosa yang bisa salah hitung [6]. Pemindahan komputasi ke penafsir program membuat jawaban dihitung alih-alih ditebak [7]. Penelitian ini memakai semangat yang sama, yaitu LLM tidak pernah memegang angka, ia hanya mengusulkan operasi, dan program di luar model yang menghitung dan mengecek.

C. Penalaran Terverifikasi untuk Time Series

Arah yang paling dekat dengan penelitian ini menggarap penalaran *time series* yang dapat diverifikasi melalui sintesis dan penjadwalan data berpikir, yang dikenal sebagai VeriTime [3]. Penelitian kami diletakkan langsung terhadap arah tersebut, dengan pembeda menggabungkan penalaran terverifikasi dan hemat *token* serta membangun data sendiri dari konteks lokal. Klaim bahwa arah terverifikasi cenderung menghasilkan penalaran panjang dan mahal masih perlu dicek terhadap naskah aslinya sebelum dipakai sebagai poros pembeda.

D. Efisiensi Token dan Penalaran Adaptif

Panjang penalaran dapat dibuat hemat dan menyesuaikan tingkat kesulitan lewat pengaturan anggaran *token*, meski sejauh ini terbatas pada soal matematika [4]. Penalaran panjang berbasis pembelajaran penguatan juga menjadi lazim setelah 2025 [10]. Gagasan anggaran adaptif itu kami pinjam dan bawa ke ranah *time series*, yang belum pernah dilakukan.

E. Pelatihan Hemat Sumber Daya

Adaptasi peringkat rendah dan kuantisasi NF4 4-bit memungkinkan penyetelan model 7B pada GPU kelas T4 atau V100 [8][9]. Untuk deret panjang, pendekatan penyandi bergaya *reprogramming* dapat menjadi opsi tambahan [12]. Karena kekuatan proyek ada pada data dan *grounding*, model kelas 7B seperti Qwen2.5 dinilai memadai tanpa perlu ukuran besar [11].

III. USULAN PENELITIAN

Penelitian ini memisahkan tiga hal yang jangan tertukar, yaitu data sebagai bahan, metode sebagai cara membuat penalaran yang *grounded* dan hemat, serta metrik sebagai alat ukur. Metodenya terdiri atas dua komponen berbeda sifat, yaitu komponen model berupa LLM yang disetel dan komponen program berupa verifikator deterministik yang tidak dilatih. Posisi kami terhadap karya terkait diringkas pada Tabel I. Celah yang kami ambil adalah penalaran terverifikasi yang sekaligus hemat *token* di atas data lokal.


TABEL I. POSISI PENELITIAN INI TERHADAP KARYA TERKAIT

Karya	Terverifikasi	Hemat token	Time series	Data lokal
CoT / PoT [6][7]	sebagian	tidak	tidak	-
SelfBudgeter [4]	tidak	ya	tidak	-
VeriTime [3]	ya	tidak	ya	tidak
Usulan kami	ya	ya	ya	ya

IV. METODOLOGI

A. Gambaran Sistem

Alur inti sistem berjalan sebagai berikut. LLM menerima deret angka beserta pertanyaan, lalu menuliskan penalaran dalam bentuk langkah beroperasi, bukan prosa bebas. Verifikator deterministik di luar model kemudian menghitung ulang tiap operasi atas deret asli dan mengecek apakah angka yang diklaim cocok dalam toleransi. LLM yang menalar, program yang mengoreksi. Keduanya benda terpisah yang bekerja bersama, bukan program yang ditanam ke dalam LLM. Gambaran alur ini ada pada Gambar 1.



Gambar 1. Arsitektur sistem: pemisahan komponen model (LLM penalar) dan komponen program (verifikator deterministik).

B. Konstruksi Dataset

Deret angka diambil dari sumber publik nyata lewat *scraping* atau API, jadi bukan *dataset* siap pakai (Tabel II). Untuk tiap deret, kami menyusun pertanyaan, menghitung jawaban benar dengan rumus, lalu menyusun langkah penalaran yang tiap angkanya dicek ke deret. Langkah dibatasi pada pustaka operasi yang sudah ditetapkan agar tiap langkah bisa dihitung ulang. Untuk mencapai skala, sebagian besar data latihan dibuat semi-sintetis, yaitu deret nyata atau deret terkendali yang dipasangkan dengan penalaran lalu diperiksa otomatis, sedangkan data uji didominasi deret asli agar terbukti bekerja di lapangan. Pembagian data distratifikasi menurut jenis tugas dan tingkat kesulitan, dan sumber pada data uji dijaga tidak muncul pada data latihan supaya tidak bocor.

TABEL II. SUMBER DERET PUBLIK YANG DIRENCANAKAN

Domain	Sumber	Metode akses	Frekuensi	Contoh variabel
Harga pangan	PIHPS Bank Indonesia	Scraping / API	Harian	Beras, cabai, minyak goreng
Kesehatan	Dashboard Kemenkes	Scraping	Mingguan	Kasus DBD, ISPA, diare
Cuaca	BMKG	API / scraping	Harian, jam	Suhu, curah hujan, kelembapan
Energi	Sumber beban terbuka	API	Jam	Beban dan konsumsi listrik

C. Skema JSONL dan Pustaka Operasi

Data disimpan sebagai JSONL, satu sampel per baris. Tiap sampel memuat empat bagian, yaitu deret berisi nama, satuan, frekuensi, dan nilai; konteks beserta pertanyaan; daftar penalaran yang tiap langkahnya berisi operasi, hasil yang diklaim, dan teks; serta jawaban berisi label dan tingkat keyakinan. Tiap langkah menamai satu operasi dari pustaka tetap pada Tabel III agar bisa dijalankan ulang oleh verifikator. Operasi majemuk dapat disusun dari operasi dasar.

TABEL III. PUSTAKA OPERASI DASAR

Operasi	Arti	Contoh
rata2(rentang)	rata-rata pada rentang	rata2(nilai[0:5])
delta(a, b)	selisih dua titik	delta(nilai[0], nilai[15])
persen_naik(a, b)	perubahan persen	persen_naik(nilai[11], nilai[15])
rasio(a, b)	perbandingan dua nilai	rasio(nilai[15], baseline)
slope(rentang)	kemiringan tren linear	slope(nilai[10:16])
min / max(rentang)	nilai ekstrem	max(nilai)
z_score(titik)	deviasi dalam simpangan baku	z_score(nilai[15])
deteksi_anomali(ambang)	titik melewati ambang	deteksi_anomali(z=3)
bandingkan_segmen(r1, r2)	banding dua segmen	bandingkan_segmen(nilai[0:8], nilai[8:16])

D. Verifikator Deterministik dan Skor Grounding

Verifikator adalah program di luar LLM, ditulis dengan Python dan NumPy serta tidak dilatih. Program ini membaca string operasi tiap langkah, menerjemahkan tokennya (nilai[a:b] menjadi irisan, nilai[i] menjadi satu elemen, angka menjadi literal, atau nama menjadi hasil langkah sebelumnya), menghitung ulang atas deret asli, lalu membandingkan hasilnya dengan angka yang diklaim. Satu langkah disebut *grounded* bila memenuhi persamaan (1).

$$|v_{hitung} - v_{klaim}| \leq \max(\varepsilon_{abs}, \varepsilon_{rel} \cdot |v_{hitung}|) \quad (1)$$

dengan nilai bawaan kedua toleransi, absolut dan relatif, sama dengan 0,01. Suku relatif berperan sebagai penyetel kalibrasi. Suku ini membuat nilai tersaji 105,3 tetap lolos terhadap hasil hitung ulang 105,26 yang hanya beda pembulatan, sementara salah besaran yang nyata, misalnya 30 lawan 105, tetap gagal. Skor *grounding* satu sampel dihitung dengan persamaan (2).

$$\text{Skor } grounding = \frac{n_{grounded}}{n_{skalar}} \times 100\% \quad (2)$$

Langkah bukan skalar, misalnya deteksi_anomali yang mengembalikan daftar indeks, untuk sementara tidak dihitung dalam skor skalar. Verifikator dipakai di tiga tempat, yaitu membersihkan label saat membangun data dengan membuang langkah yang gagal, menghitung skor *grounding* saat evaluasi, dan secara opsional menjadi sinyal imbalan saat pelatihan.

E. Penalaran Adaptif

Panjang penalaran diatur menurut kesulitan. Deret dengan pola jelas cukup diberi penalaran pendek, sedangkan deret yang ambigu diberi penalaran panjang. Cara ini menekan jumlah *token* tanpa menurunkan akurasi, mengikuti gagasan anggaran *token* adaptif [4] yang kami bawa ke ranah *time series*.

F. Protokol Pelatihan

Penyetelan memakai QLoRA 4-bit agar muat pada GPU T4 atau V100 (Tabel IV). Model kelas 7B dinilai cukup karena kekuatan proyek ada pada data dan *grounding*. Sebagai perluasan opsional, pembelajaran penguatan dengan imbalan terverifikasi memberi nilai lebih ketika langkah penalaran lolos pemeriksaan *grounding*.

TABEL IV. KONFIGURASI PELATIHAN KANDIDAT

Parameter	Nilai	Parameter	Nilai
Metode	QLoRA (NF4 4-bit)	Penjadwal	cosine + warmup
Peringkat LoRA	16 sampai 64	Presisi	bf16
Alfa LoRA	32	Epoch	2 sampai 3
Laju belajar	1e-4 sampai 2e-4	Kerangka	LLaMA-Factory, ZeRO-2

V. HASIL AWAL DAN RANCANGAN EKSPERIMEN

Catatan penting. Penelitian masih pada Fase 1 atau fondasi. Bagian V.A sampai V.C melaporkan hasil awal yang nyata dan bisa direproduksi dari verifikator, sedangkan bagian V.D dan V.E memaparkan rancangan eksperimen penuh yang akan dijalankan pada Fase 4 dan 5. Tidak ada angka hasil model terlatih yang diklaim pada draf ini.

A. Implementasi Fondasi

Empat modul inti sudah dibuat dan diuji, yaitu skema JSONL, pustaka operasi berbasis NumPy, verifikator, dan modul metrik. Seluruh fondasi lolos 20 pengujian otomatis yang mencakup kebenaran tiap operasi, baca tulis JSONL bolak-balik, validasi skema, serta perhitungan skor *grounding*.

B. Studi Kasus: Deteksi Wabah DBD

Untuk deret kasus DBD mingguan sebuah kabupaten selama 16 minggu pada Tabel V, penalaran jujur menyusun tiga langkah. Verifikator menghitung ulang tiap operasi atas deret asli lalu mencocokkannya dengan angka yang diklaim. Ketiganya *grounded*, sehingga skor *grounding* mencapai 100 persen dan mendukung kesimpulan wabah dengan keyakinan tinggi.

TABEL V. REPRODUKSI PENALARAN JUJUR, SKOR GROUNDING 100 PERSEN

Lgk.	Operasi	Diklaim	Hitung ulang	Grounded
1	rata2(nilai[0:5])	13,0	13,0	ya
2	persen_naik(nilai[11], nilai[15])	105,3	105,26	ya
3	rasio(nilai[15], 13,0)	6,0	6,0	ya

C. Validasi Deteksi Halusinasi

Untuk menguji apakah metrik menangkap kesalahan nyata, langkah kedua diubah menjadi klaim salah besaran, yaitu 30 persen padahal 105 persen. Verifikator menandai langkah itu tidak *grounded* karena selisih 75,26 jauh melampaui toleransi pada persamaan (1), sehingga skor *grounding* turun menjadi 66,7 persen (Tabel VI). Inilah metrik yang menjadi tumpuan proyek, yaitu kejujuran penalaran terhadap angka yang dihitung tanpa LLM penilai.

TABEL VI. DETEKSI HALUSINASI SALAH BESARAN, SKOR GROUNDING 66,7 PERSEN

Lgk.	Operasi	Diklaim	Hitung ulang	Grounded
1	rata2(nilai[0:5])	13,0	13,0	ya
2	persen_naik(nilai[11], nilai[15])	30,0	105,26	tidak
3	rasio(nilai[15], 13,0)	6,0	6,0	ya

D. Rancangan Eksperimen Penuh

Empat eksperimen dirancang untuk menjawab RQ1 sampai RQ4. Pertama, uji halusinasi dasar dengan menguji model tanpa penyetelan pada tolok ukur kami untuk membuktikan skor *grounding* rendah. Kedua, uji metode lawan pembandingan untuk menunjukkan skor *grounding* naik tanpa menurunkan akurasi. Ketiga, uji efisiensi dengan membandingkan *token* penalaran adaptif lawan penalaran panjang pada akurasi setara. Keempat, uji ablasi dengan mematikan komponen satu per satu, yaitu verifikator saat pelatihan, penalaran adaptif, dan format beroperasi, untuk mengukur sumbangan tiap bagian. Pembandingnya mencakup LLM umum tanpa penyetelan yang menulis prosa bebas, LLM dengan penalaran panjang bergaya terverifikasi tanpa penghematan sebagai wakil arah VeriTime [3], dan metode statistik murni sebagai batas atas hitungan tanpa penjelasan.

E. Metrik dan Hasil yang Diharapkan

Tiga metrik dipakai dan semuanya deterministik, yaitu akurasi jawaban berupa persentase label akhir yang benar, skor *grounding* pada persamaan (2) sebagai metrik utama, dan efisiensi *token* berupa rata-rata *token* penalaran per sampel yang dilaporkan bersama akurasi agar imbangannya terlihat. Hasil yang diharapkan meliputi *dataset* penalaran *time series* terverifikasi yang siap dipakai ulang, bukti bahwa model sekarang berhalusinasi dengan skor *grounding* rendah, bukti bahwa metode kami menaikkan *grounding* tanpa menurunkan akurasi dan lebih hemat *token*, serta prototipe utuh yang bisa menjawab pertanyaan atas deret dengan penalaran yang bisa diperiksa.

VI. KESIMPULAN DAN SARAN

A. Kesimpulan

Draf ini menetapkan fondasi sebuah pendekatan penalaran *time series* yang memisahkan LLM penalar dari verifikator deterministik, dengan penalaran berbentuk operasi yang tiap angkanya bisa dihitung ulang. Fondasinya sudah terbukti pada studi kasus nyata. Verifikator mereproduksi penalaran jujur pada deret DBD dengan skor *grounding* 100 persen dan

menandai penalaran berhalusinasi dengan skor turun ke 66,7 persen, serta lolos 20 pengujian. Sumbangan untuk kompetensi data mining adalah data lokal terverifikasi yang usaha pembuatannya besar, dipasangkan dengan metode yang bisa diaudit dan hemat *token*.

B. Saran dan Rencana Kerja

Pekerjaan berikutnya mengikuti enam fase, yaitu finalisasi pustaka operasi dan skema pada Fase 1, *scraping* deret dari sumber publik pada Fase 2, sintesis dan verifikasi lapisan penalaran pada Fase 3, penyetelan model dan integrasi alur pada Fase 4, eksperimen serta ablasi dan evaluasi pada Fase 5, dan pembuatan prototipe serta penulisan laporan pada Fase 6. Titik paling menentukan ada di Fase 1 dan 3 karena pustaka operasi dan verifikasi label menentukan seluruh data. Risiko utama berupa tumpang tindih dengan VeriTime ditekankan dengan menegaskan gabungan penalaran terverifikasi dan hemat *token* serta data lokal buatan sendiri. Dari sisi etika, seluruh sumber bersifat publik, sistem diposisikan sebagai penunjang keputusan dan bukan nasihat medis atau finansial pribadi, dan penalaran yang *grounded* justru mendukung pertanggungjawaban karena jejak hitungannya bisa ditelusuri.

REFERENSI

- [1] M. Merrill, M. Tan, V. Gupta, T. Hartvigsen, dan T. Althoff, "Language Models Still Struggle to Zero-shot Reason about Time Series," dalam Findings of EMNLP, 2024.
- [2] "MTBench: A Multimodal Time Series Benchmark for Temporal Reasoning and Question Answering," arXiv:2503.16858, 2025.
- [3] "VeriTime: Time Series Reasoning via Process-Verifiable Thinking Data Synthesis and Scheduling for Tailored LLM Reasoning," arXiv:2602.07830, 2026.
- [4] "SelfBudgeter: Adaptive Token Allocation for Efficient LLM Reasoning," arXiv:2505.11274, 2025.
- [5] "TimeOmni-1: Incentivizing Complex Reasoning with Time Series in Large Language Models," dalam Proc. ICLR, 2026.
- [6] J. Wei et al., "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models," dalam Proc. NeurIPS, 2022.
- [7] L. Gao et al., "PAL: Program-aided Language Models," dalam Proc. ICML, 2023.
- [8] E. J. Hu et al., "LoRA: Low-Rank Adaptation of Large Language Models," dalam Proc. ICLR, 2022.
- [9] T. Dettmers, A. Pagnoni, A. Holtzman, dan L. Zettlemoyer, "QLoRA: Efficient Finetuning of Quantized LLMs," dalam Proc. NeurIPS, 2023.
- [10] DeepSeek-AI, "DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning," arXiv:2501.12948, 2025.
- [11] Qwen Team, "Qwen2.5 Technical Report," arXiv:2412.15115, 2024.
- [12] M. Jin et al., "Time-LLM: Time Series Forecasting by Reprogramming Large Language Models," dalam Proc. ICLR, 2024.
- [13] Y. Zheng et al., "LLaMA-Factory: Unified Efficient Fine-Tuning of 100+ Language Models," dalam Proc. ACL System Demonstrations, 2024.
- [14] Bank Indonesia, "Pusat Informasi Harga Pangan Strategis Nasional," tersedia di <https://www.bi.go.id/hargapangan>, diakses [tanggal].
- [15] Kementerian Kesehatan RI, "Dashboard Data Penyakit," tersedia di [URL], diakses [tanggal].
- [16] BMKG, "Data Online Pusat Database BMKG," tersedia di <https://dataonline.bmkg.go.id>, diakses [tanggal].